

推导完全分类

我会把这次问题转成严格的 OOS 因果选择器检验，而不是再讨论结构覆盖：核心是区分 in-sample 正类筛选、level0 卖类的可检验性，以及方向/窗口偏差。

结论先给清楚：

缠论结构识别层不过拟合；因果选择器的 $\hat{\mu}(z, a)$ 估计层会过拟合。

这不是缠论的问题，而是统计学习问题。你的结构分类器

$$C_{\Theta} : x \mapsto z$$

可以是完全确定的、零参数的；但一旦你做：

$$\hat{\mu}(z, a) = \frac{1}{n_z} \sum_{m: z_m = z} X_m(a), \quad \chi_t(z, a) = \mathbf{1}[\hat{\mu}(z, a) > \theta],$$

你就在用历史收益样本估条件期望并挑选高分状态。这里会出现 winner's curse、多重比较、小样本高方差、数据窥探。你上传的形式化文件里已经把元素、级别、方向、BSP 这些语法对象定义为确定结构；BSP 是元素的子集，AncOK 也只是活动集合法性约束，这些都是结构层命题，不是收益估计命题。

1. 严格分层：哪里不会过拟合，哪里会过拟合

设缠论结构分类器为：

$$C_{\Theta} : \mathcal{X} \rightarrow \mathcal{Z}.$$

它把状态 x_t 映射到：

$$z_t = C_{\Theta}(x_t),$$

例如：

$$z = (\ell, \delta, I_{\gamma}, \text{父方向}, \text{短差/顺势}, \text{仓位态}, \dots).$$

如果 C_{Θ} 完全由 K 线递归规则决定，没有用历史收益调整任何参数，那么：

C_{Θ} 本身没有统计拟合，因此没有统计意义上的过拟合。

但 alpha 选择器不是 C_{Θ} 。alpha 选择器是：

$$\chi_t(z, a) = \mathbf{1}[\hat{\mu}_t(z, a) > \theta].$$

其中：

$$\hat{\mu}_t(z, a)$$

是训练样本上的条件收益均值。它是随机估计量，所以会过拟合。

因此：

过拟合不在“缠论分类器”，而在“收益估计器 + 选择器”。

2. 样本均值为什么必然会过拟合？

对某个状态—动作对 (z, a) ，设真实条件收益为：

$$\mu(z, a) = \mathbb{E}[X(a) \mid Z = z].$$

训练样本数为：

$$n_z.$$

样本估计为：

$$\hat{\mu}(z, a) = \frac{1}{n_z} \sum_{j=1}^{n_z} X_j(a).$$

写成：

$$\hat{\mu}(z, a) = \mu(z, a) + \varepsilon_z,$$

其中：

$$\mathbb{E}[\varepsilon_z] = 0, \quad \text{Var}(\varepsilon_z) = \frac{\sigma_z^2}{n_z}.$$

当 n_z 很小时，

$$\frac{\sigma_z}{\sqrt{n_z}}$$

很大。于是很多状态的 $\hat{\mu}$ 会因为噪声变大正数。

你的选择器：

$$\chi(z, a) = 1[\hat{\mu}(z, a) > \theta]$$

会把这些噪声正值当成 alpha。

这就是 winner's curse。

3. 严格定理：零 alpha 下，挑高分必然产生 in-sample 假阳性

假设有 K 个状态类别：

$$z_1, \dots, z_K.$$

在零 alpha 世界中：

$$\mu(z_k, a) = 0 \quad \forall k.$$

假设估计误差近似：

$$\hat{\mu}_k \sim N\left(0, \frac{\sigma^2}{n}\right)$$

且相互独立。

则：

$$\max_{1 \leq k \leq K} \hat{\mu}_k$$

的期望近似为：

$$\mathbb{E} \left[\max_k \hat{\mu}_k \right] \approx \frac{\sigma}{\sqrt{n}} \sqrt{2 \log K}.$$

所以只要 K 多，哪怕所有真实 $\mu_k = 0$ ，训练集中也会出现看起来很正的类别。

这就是多重比较。

更直接地，若阈值为 $\theta = 0$ ，则：

$$\mathbb{P}(\hat{\mu}_k > 0) = 1/2.$$

所以期望被选中的假阳性类别数为：

$$\mathbb{E}[\#\{k : \hat{\mu}_k > 0\}] = K/2.$$

如果 $K = 300$ ，那么即使真实没有任何 alpha，训练集中也会有约 150 个类别看起来为正。

4. Winner's curse 的数学形式

在零 alpha 下：

$$\mu = 0, \quad \hat{\mu} \sim N(0, \sigma^2/n).$$

条件在训练集中被选中：

$$\hat{\mu} > \theta.$$

那么训练内估计均值满足：

$$\mathbb{E}[\hat{\mu} \mid \hat{\mu} > \theta] = \frac{\sigma}{\sqrt{n}} \frac{\varphi(a)}{1 - \Phi(a)}, \quad a = \frac{\theta\sqrt{n}}{\sigma}.$$

这个量严格大于 θ 。

但 OOS 真期望仍是：

$$\mathbb{E}[X_{\text{OOS}} \mid \hat{\mu} > \theta] = \mu = 0.$$

扣成本后：

$$\mathbb{E}[X_{\text{OOS}} - C \mid \hat{\mu} > \theta] \leq 0.$$

所以：

训练内正收益 \textcolor{red}{centernot} $\Rightarrow$ OOS 正收益。

这正是你说的：

variance-estimation noise relabeled as signal.

5. 状态空间组合爆炸为什么特别严重？

你给的状态：

$$z = (\ell, \delta, I_\gamma, \text{父方向}, \text{短差/顺势}, \text{仓位态})$$

大致数量级为：

$$K \approx |\ell| \cdot 2 \cdot |I_\gamma| \cdot 3 \cdot 2 \cdot |\omega|.$$

若：

$$|\ell| = 6, \quad |I_\gamma| = 7, \quad |\omega| = 3,$$

则：

$$K \approx 6 \cdot 2 \cdot 7 \cdot 3 \cdot 2 \cdot 3 = 1512.$$

即使很多状态不会出现，实际出现几百类也很正常。

而高级别信号天然稀疏。若某类只有：

$$n_z = 1, 2, 3,$$

则：

$$\text{se}(\hat{\mu}_z) = \sigma_z / \sqrt{n_z}$$

非常大。此时样本均值几乎不能作为条件期望。

所以：

高维状态分类 + 高级别稀疏 $\Rightarrow \hat{\mu}(z)$ 极易过拟合。

6. 严格回答 Q1：level0 卖 349 个样本能不能 OOS 验证？

可以，但必须满足两个条件。

条件一：这个类别必须预先指定

如果你先看全样本，再发现：

$$z = \text{level0 卖}$$

是赢家，然后说“我要验证它”，那么它仍然带有选择偏差。

严格说，若它是从很多类别中事后挑出来的，就要做多重比较修正或重新留出完全未见过的数据验证。

正确做法是：

先在 train 中决定 level0 卖是否为可交易类别，再在 OOS 中验证。

如果 level0 卖是你事前理论指定的唯一主检验类别，则 $n = 349$ 已经具备一定检验能力。

条件二：必须用有效样本数，而不是原始信号数

设 OOS 中该类事件数为：

$$n_{\text{raw}}.$$

由于交易收益可能重叠、时间相关、同一趋势段内多信号相关，有效样本数应为：

$$n_{\text{eff}} = \frac{n_{\text{raw}}}{1 + 2 \sum_{k=1}^K \rho_k},$$

其中 ρ_k 是收益序列自相关。

如果：

$$n_{\text{raw}} = 349,$$

但事件高度聚集，可能：

$$n_{\text{eff}} \ll 349.$$

349 样本的最小可检出效应

标准化效应大小：

$$d = \frac{\mu - \theta}{\sigma}.$$

一侧 5% 显著、80% 功效近似需要：

$$n \gtrsim \frac{6.19}{d^2}.$$

反过来，在 $n = 349$ 下，可检测效应约为：

$$d_{\min} \approx \sqrt{\frac{6.19}{349}} \approx 0.133.$$

如果 OOS 切半后只有：

$$n \approx 175,$$

则：

$$d_{\min} \approx \sqrt{\frac{6.19}{175}} \approx 0.188.$$

所以结论是：

level0 卖的 349 信号有可能单独 OOS 验证，但必须做预注册、时间切分、有效样本修

如果它是事后赢家，就不能直接把 +34,684 当真 alpha。

7. Q2: Shrinkage + LCB 是否是标准正确解？

是。严格说：

shrinkage 解决高方差；LCB 解决选择风险。

二者互补。

7.1 层级收缩模型

设某个状态 z 属于一个更粗组 $g(z)$ ，例如：

$$g(z) = (\ell, \delta)$$

或：

$$g(z) = (\ell, \delta, I_\gamma).$$

假设：

$$\mu_z \sim N(m_{g(z)}, \tau^2),$$

样本均值：

$$\bar{X}_z \mid \mu_z \sim N\left(\mu_z, \frac{\sigma_z^2}{n_z}\right).$$

则后验均值为：

$$\tilde{\mu}_z = w_z \bar{X}_z + (1 - w_z) m_{g(z)}.$$

其中：

$$w_z = \frac{\tau^2}{\tau^2 + \sigma_z^2/n_z} = \frac{n_z}{n_z + \sigma_z^2/\tau^2}.$$

当 n_z 小：

$$w_z \approx 0,$$

于是估计收缩到 pooled mean。

当 n_z 大：

$$w_z \approx 1,$$

于是估计接近本类样本均值。

这正是你说的：

$$\hat{\mu}_{\text{shrink}} = w \cdot \bar{X}_z + (1 - w) \cdot \text{pooled mean}.$$

7.2 shrinkage 的严格意义

在上述正态—正态层级模型下，后验均值是平方损失下的 Bayes 最优估计器：

$$\tilde{\mu}_z = \mathbb{E}[\mu_z \mid \bar{X}_z].$$

因此它最小化后验均方误差：

$$\mathbb{E}[(\hat{\mu} - \mu_z)^2 \mid \bar{X}_z].$$

所以：

shrinkage 是该层级假设下的最优估计。

它不是拍脑袋修补，而是标准贝叶斯/经验贝叶斯处理稀疏 cell means 的方法。

7.3 LCB

定义置信下界：

$$LCB_z = \tilde{\mu}_z - c_\alpha \widehat{se}_z.$$

交易选择器：

$$\chi_z = 1[LCB_z > \theta].$$

含义是：

只有当估计均值扣掉不确定性后仍超过门槛，才交易。

这能压制小样本噪声赢家。

7.4 还有更本质的解吗？

有三类。

第一：降低状态维数

不要让：

$$z = (\ell, \delta, I_\gamma, \sigma_p, r, \omega, \dots)$$

无限组合。应先用理论决定哪些交互项保留。

例如：

$$\mu(z) = \beta_0 + \beta_\ell + \beta_\delta + \beta_I + \beta_r + \beta_{\ell,\delta} + \beta_{\delta,r} + f(\text{backchi strength}).$$

而不是每个 z 独立一个均值。

第二：正则化模型

比如 ridge / lasso / elastic net / Bayesian hierarchical model：

$$X_m = f_\theta(z_m) + \varepsilon_m.$$

用正则化约束模型复杂度。

第三：严格 OOS 选择

所有：

$$\hat{\mu}, \quad shrinkage, \quad LCB, \quad \text{阈值}\theta$$

都必须在 train 内确定。

OOS 只评估：

$$R_{\text{OOS}}.$$

否则又会 winner's curse。

8.Q3：高级别稀疏是否单品种无解？

如果没有跨类别、跨品种结构假设，基本无解。

严格说，估计某个类别均值 μ_z 的误差下界是：

$$\text{se}(\hat{\mu}_z) \approx \frac{\sigma_z}{\sqrt{n_z}}.$$

若：

$$n_z = 1, 2, 3,$$

则没有任何估计器能可靠区分：

$$\mu_z = 0$$

和：

$$\mu_z = \text{小正数}.$$

可以用 Le Cam 型下界说明。

Le Cam 二点下界

考虑两个模型：

$$H_0 : X_i \sim N(0, \sigma^2),$$

$$H_1 : X_i \sim N(\Delta, \sigma^2).$$

样本数为 n 。

两者 KL 散度：

$$KL(H_0, H_1) = \frac{n\Delta^2}{2\sigma^2}.$$

若：

$$\frac{n\Delta^2}{\sigma^2} \ll 1,$$

则两个分布统计上很难区分。任何检验的错误率都远离 0。

也就是说：

$$\boxed{n\Delta^2/\sigma^2}$$

太小时，不存在可靠识别 α 的方法。

所以高级别稀疏类别如果没有 pooling，确实是信息论硬墙。

9. 跨品种 pooling 的严格前提

跨品种 pooling 不是免费午餐。

它依赖部分可交换假设：

$$\mu_{a,z} = \mu_z + u_{a,z},$$

其中：

$$u_{a,z} \sim N(0, \tau_{\text{asset}}^2).$$

如果：

$$\tau_{\text{asset}}^2$$

小，说明不同品种同类状态的条件收益接近，pooling 有效。

如果：

$$\tau_{\text{asset}}^2$$

大，说明品种差异很强，pooling 会引入偏差。

所以 pooling 的可信性必须验证：

- leave-one-asset-out；
- posterior predictive check；
- 分品种残差检查；
- 同类状态跨品种符号一致性；
- regime 分层。

严格结论：

跨品种 pooling 可以提高功效，但代价是引入“同级别同状态跨品种可交换”的建模假设。

这个假设不一定真，必须 OOS 验证。

10. 你的 L3 inconclusive 的严格判定

现在你的情况是：

- 结构解释器通过；
- μ 估计器有；
- χ 过滤有；
- 鞅守卫通过；
- L3 实证：2 确认、3 否认、3 退化，有效 $n = 5$ ，符号检验 3/5， $p=0.5$ 。

这不是 alpha 否认。

严格理由：

$$K \sim \text{Binomial}(5, 1/2).$$

一侧符号检验要显著，只有：

$$K = 5$$

时：

$$P(K \geq 5) = 1/32 = 0.03125.$$

若 $K = 4$ ：

$$P(K \geq 4) = 6/32 = 0.1875.$$

若 $K = 3$ ：

$$P(K \geq 3) = 16/32 = 0.5.$$

所以 3/5 的 $p=0.5$ 只是功效不足。

它既不确认 alpha，也不否认 alpha。

11. 正确的下一步验收

对 level0 卖

因为有 349 信号，它是最值得单独验证的类别。

但验证必须是：

预注册 level0 卖 $\rightarrow$ train 决定规则 $\rightarrow$ OOS 验证

不能用全样本挑赢家。

具体：

1. 多窗口 walk-forward;
2. 每个 train 只用过去估计;
3. OOS 只执行预定规则;
4. 用事件收益:

$$X_m = \delta(P_{\tau_m} - P_{t_m}) - C_m.$$

5. 用 block bootstrap / HAC / cluster by time 估置信区间;
6. 报告:

$$\hat{\mu}_{\text{OOS}}, \quad se, \quad LCB, \quad p\text{-value}.$$

如果 OOS 下 level0 卖仍显著为正，才可说有初步 alpha。

对高级别类

level2=12、level3=1-3 这种样本，不要直接估独立 μ_z 。

用：

层级收缩 + LCB + 多窗口/多品种 pooling

否则就是噪声赢家。

12. 最终严格结论

你的直觉应修正为：

缠论结构分类器不过拟合。

但：

缠论状态上的历史收益均值估计器会过拟合。

形式上：

$$C_{\Theta} : x \mapsto z$$

是确定函数，不拟合收益；

但：

$$\hat{\mu}(z) = \frac{1}{n_z} \sum X_m$$

是随机估计器；

$$\chi(z) = 1[\hat{\mu}(z) > \theta]$$

是基于随机估计器的选择规则。

当 K 大、 n_z 小时：

$$\max_z \hat{\mu}(z)$$

会显著正偏，即使所有真实 $\mu(z) = 0$ 。

所以过拟合来源是：

稀疏条件收益估计 + 多重比较选择。

标准解是：

降低有效维数 + 层级收缩 + LCB + 严格 OOS + block/cluster 检验

而高级别稀疏的根本硬墙是：

$$n_z d_z^2$$

太小就不可识别。

所以你现在的判断是正确的：

不是“缠论过拟合”，而是“在缠论状态上估 μ 的统计学习器过拟合”。

下一步最有价值的是：

把 level0 卖作为预注册单类做 OOS 验证；

同时：

对高级别类做层级收缩和跨品种 pooling，而不是独立样本均值挑赢家。



